

КУРС “ЦИФРОВАЯ АРХИВАЦИЯ”

Архивация специализированных ресурсов

Специальный контент

По способу извлечения

Материалы которые не поддаются архивации “классической” веб-архивации и требуют использования или создания новых инструментов их сбора

По способу представления

Контент который имеет другие формы представления чем веб-страницы. Например, игры или базы данных

Как можно описать “нестандартные виды контента”?

1

Материалы доступные только после авторизации

Телеграм, соцсети, иной контент за авторизацией

2

Контент доступный через специальные API

Некоторые сайты, соцсети, специализированные продукты для публикации научных статей (DSpace, Invenio), репозитории исходного кода

3

Файловые хранилища (облачные, FTP и др.)

Хранилища файлов такие как Яндекс.Диск, Google Drive, Dropbox, Amazon S3 и другие

4

Контент недоступный через HTTP/Web

Данные интернета устройств, топологии Интернета, прошивок устройств и так далее.

Контент требующий специальных способов отображения

- 1 Базы данных
- 2 Компьютерные игры
- 3 Программный исходный код
- 4 Компьютерные программы
- 5 Мультимедиа объекты (видео/аудио)
- 6 3-х мерные модели

Для всего есть свои инструменты и архивы

Категория	Тип контента	Инструменты	Архив
Исходный код	Система контроля версий Git	git	Software Heritage
Соцсети	Twitter	twarc	-
Соцсети	Instagram	instaloader	-
Файловое хранилище	Яндекс Диск	ydiskarc	-
Специальный контент	Научные публикации	-	OpenAIRE
Специальный контент	Открытые данные	apibackuper	СКАН, Zenodo, Dataverse

Инструменты

Twarc

<https://github.com/DocNow/twarc>

- архивирует сообщения из твиттер
- сохраняет в файлы в формате JSON
- только командная строка
- работает под Windows, Linux, Mac

Установить

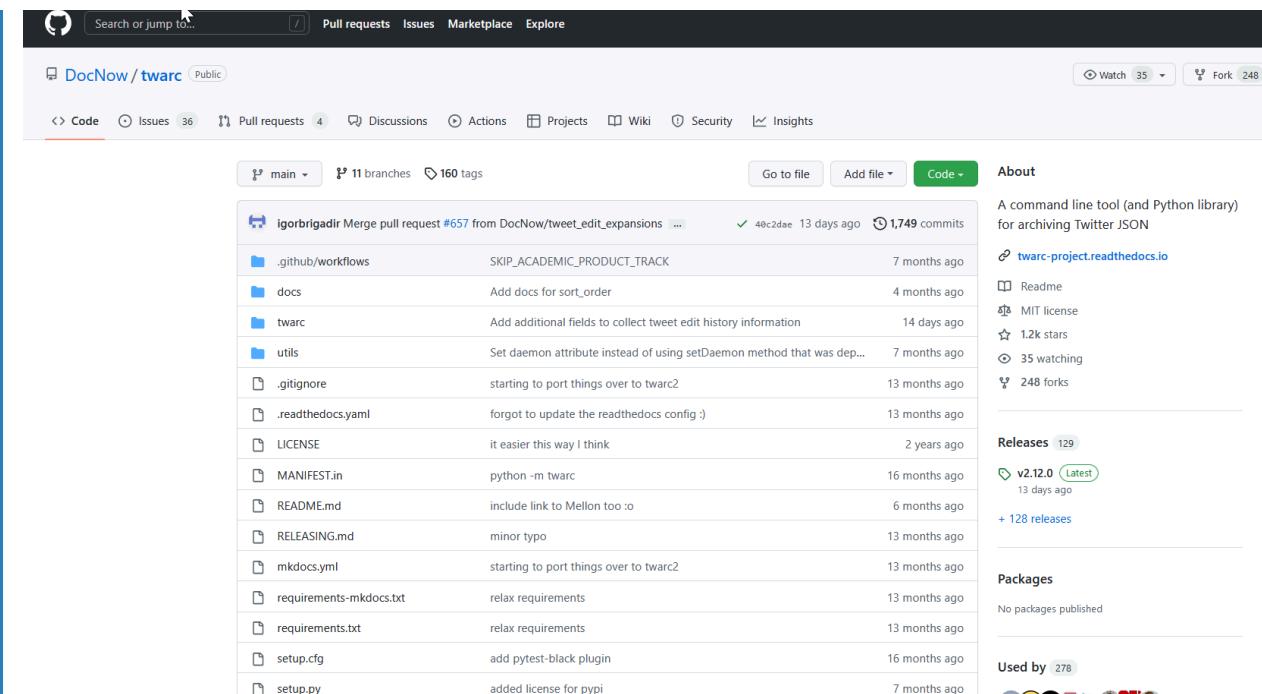
pip install twarc

Настроить

twarc configure

Сохранить твиты аккаунта НИУ ВШЭ

twarc timeline SU_HSE



Instaloader

<https://github.com/instaloader/instaloader>

- архивирует сообщения, фото и видео из Инстаграм
- сохраняет в файлы в формате JSON
- только командная строка
- работает под Windows, Linux, Mac

Установить

`pip3 install instaloader`

Сохранить сообщения

`instaloader profile <название аккаунта>`

The screenshot shows the GitHub repository page for Instaloader. At the top, there's a large green button labeled "Version 4.9.5 (Latest) 18 days ago + 117 releases". Below it, the repository name "Instaloader" is displayed with its logo, which is a stylized letter "I" with a pink and orange gradient. The repository has 2.8k stars and 2.7k forks. The README.rst file contains the following content:

```
$ pip3 install instaloader  
$ instaloader profile [profile ...]
```

The "Instaloader" section lists its features:

- downloads public and private profiles, hashtags, user stories, feeds and saved media,
- downloads comments, geotags and captions of each post,
- automatically detects profile name changes and renames the target directory accordingly,
- allows fine-grained customization of filters and where to store downloaded media,
- automatically resumes previously-interrupted download iterations.

At the bottom, there's a code block showing command-line examples:

```
instaloader [--comments] [--geotags]  
[--stories] [--highlights] [--tagged] [--igtv]  
[--login YOUR-USERNAME] [--fast-update]  
profile | "#hashtag" | :stories | :feed | :saved
```

On the right side of the page, there are sections for "Sponsor this project", "Used by", "Contributors" (showing 39 contributors), and "Languages" (Python).

APIBackuper

<https://github.com/ruarxive/apibackuper>

- архивирует данные из открытых API
- сохраняет в файлы в формате JSON
- только командная строка
- работает под Windows, Linux, Mac

Установить

pip install apibackuper

Запуск (требует конфиг файла)

apibackuper run

```
initialized = True
name = etrust

[project]
description = E-Trust UC list
url = https://e-trust.gosuslugi.ru/app/scc/portal/api/v1/portal/ca/list
http_mode = POST
work_modes = full,incremental,update
iterate_by = page

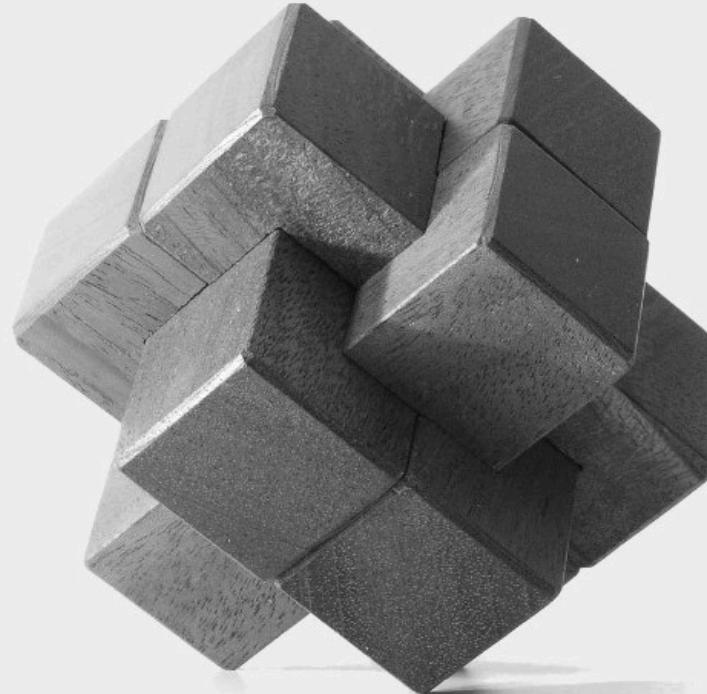
[params]
page_size_param = recordsOnPage
page_size_limit = 100
page_number_param = page

[data]
total_number_key = total
data_key = data
item_key = РеестровыйНомер
change_key = СтатусАkkредитации.ДействуетС

[storage]
```

Архивы

Software Heritage



Software is the key
to access information and
a fundamental part of
human heritage

We are building the universal software archive



Collect
Preserve

We **collect** and **preserve** software in source code form, because software embodies our technical and scientific knowledge and humanity cannot afford the risk of losing it.

Software is a precious part of our cultural heritage. We curate and make

Telegram channels and groups catalog

Russia ▾



Learn English

Прокачай свой английский

Linguistics
69 817 subscribers



Sports.ru

Новости спорта от Sports.ru

Sport
174 070 subscribers



Осторожно, новости
1 413 472 subscribers



Кровавая барыня
1 395 654 subscribers



Медуза — LIVE
1 289 637 subscribers



Readovka
1 243 495 subscribers



КРУГИ НА ПОЛЯХ
1 166 788 subscribers



НЕВЗОРОВ
1 165 245 subscribers



Дима Масленников
1 154 766 subscribers



Varlamov News
1 147 864 subscribers



НЕ МОРГЕНШТЕР
1 080 416 subscribers

28.8k	Marketing, PR, advertising
28.9k	Psychology
20.0k	Design
7.8k	Politics
8.0k	Art
14.9k	Law
12.6k	Education
7.5k	Books

6.9k	Linguistics
8.8k	Career
2.3k	Edutainment
12.2k	Courses and guides
3.6k	Sport
1.7k	Fashion and beauty
7.9k	Medicine
5.6k	Health and Fitness

2.9k	Pictures and photos
4.2k	Software & Applications
10.8k	Video and films
1.4k	Music
7.6k	Games
9.9k	Food and cooking
3.5k	Quotes
5.0k	Handiwork



Сладков +
975 568 subscribers



Олег Царёв
276 451 subscribers



Туну40k Goblina (o
462 346 subscribers

TGStat.ru

OpenAIRE

Discover open linked research.

A comprehensive and open dataset of research information covering 145m publications, 18m research data, 304k research software items, from 110k data sources, linked to 3m grants and 178k organizations.

All linked together through citations and semantics.

Type

All Content

Scholarly works

Search in Open...



Try browsing by:



SUSTAINABLE DEVELOPMENT GOALS (SDGs) →



FIELDS OF SCIENCE (FOS) →

Featured communities

Need help uploading? [Cont](#)

Transform to Open Science

[Browse](#) [New upload](#)

Transform to OPen Science (TOPS) is a \$40 million, 5-year mission, led by NASA's Science Mission Directorate's Open-Source Science initiative. Within the TOPS mission, NASA is designating 2023 as the Year Of Open Science, a community initiative to spark change and inspire open science...

Curated by: [nasatransformtoopen](#)

Recent uploads

[October 14, 2022 \(vv0.4.49\)](#) [Software](#) [Open Access](#)[View](#)

Trixi.jl

Schlottke-Lakemper, Michael; Gassner, Gregor J.; Ranocha, Hendrik; Winters, Andrew R.; Chan, Jesse

Adaptive high-order numerical simulations of hyperbolic PDEs in Julia

Uploaded on October 14, 2022

[120 more version\(s\) exist for this record](#)

[July 2, 2018 \(v2022-10-07\)](#) [Dataset](#) [Open Access](#)[View](#)

Gene Ontology Data Archive

Carbon, Seth; Mungall, Chris

Archival bundle of GO data release.

Uploaded on October 12, 2022

[48 more version\(s\) exist for this record](#)

[October 1, 2020 \(vv4.23.1\)](#) [Software](#) [Open Access](#)[View](#)

Need help?

[Contact us](#)

Zenodo prioritizes all requests related to the COVID-19 outbreak.

We can help with:

- Uploading your research data, software, preprints, etc.
- One-on-one with Zenodo supporters.
- Quota increases beyond our default policy.
- Scripts for automated uploading of larger datasets.

Why use Zenodo?

- **Safe** – your research is stored safely for the future in CERN's Data Centre for as long as CERN exists.
- **Trusted** – built and operated by CERN and OpenAIRE to ensure that everyone can join in

Zenodo

Dear Abandonia visitors: Help us keep Abandonia free with a small donation. Abandonia is like an old gaming arcade with only original games. Abandonia helps you have fun four hours and years. If Abandonia is useful to you, please help us forget fundraising and get back to Abandonia.

[Donate](#)



[Read More](#)



dedicated to classic dosgames!

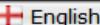


username:

password:

login!

not a member yet? [register here!](#) forgot your password?

 Search

[GAMES](#)

[NAVIGATION](#)

[AB NETWORK](#)

[FORUM](#)

[SERVICES](#)

[ADVERTISE](#)

home » games » adventure

Adventure

[1](#) [2](#) [3](#) [4](#) [5](#) [6](#) [7](#) [8](#) [9](#) ... [next](#) [last](#)

270 results for: // genre: Adventure



Tags: [Freeware](#), [Crime](#), [3rd Person](#)

5 Days a Stranger

Your rating: 3.1

Editor rating: 4

Year of release: 2003

Additional info:



[Visitor Globe](#)

Keep Abandonia Open and Free!

Your donation allows us to improve the site!



Donate

game filters

the gamefilter box helps you find your favourite game. Use the various selection boxes to select your criteria. Press **CTRL** while clicking to select multiple options!



Theme:	Perspective:	Multiplayer mode:
Arcade	1st Person	Hot Seat
Card	3rd Person	Network
Comedy	ASCII	Online
Crime	CGA-only	
Cyberpunk	Isometric	



Tags: [Freeware](#), [Mystery](#), [Sci-Fi](#), [3rd Person](#)

7 Days a Skeptic

Your rating: 3.0

Editor rating: 5

Year of release: 2004

Additional info:



A Mind Forever Voyaging

Your rating: 3.0

Добро пожаловать в Open Library



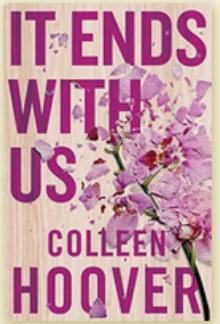
Читайте книги из
библиотек
бесплатно онлайн
Миллионы книг доступны
через Контролируемый
Цифровой Заем



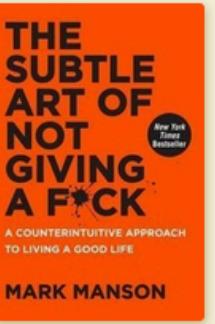
Следите за своими
любимыми книгами
Организуйте свои книги
с помощью списков и
журнала чтения



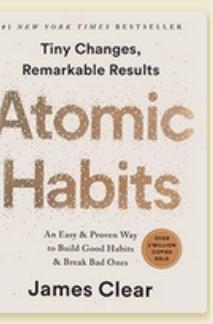
Попробуйте
виртуальный
исследователь
библиотеки
Цифровые полки
организованы как в
настоящей библиотеке

Trending Books

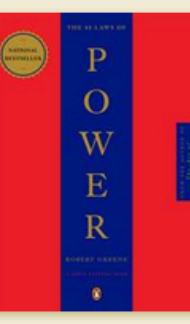
Занять



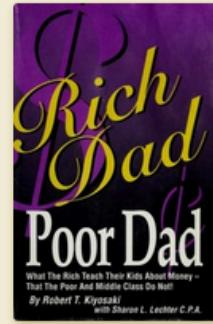
Предпросмотр



Предпросмотр



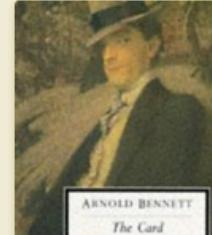
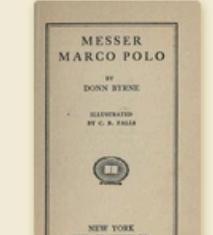
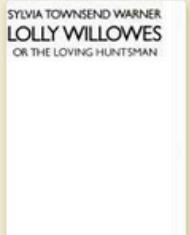
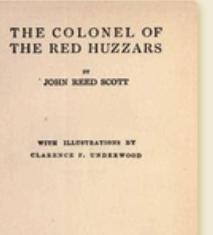
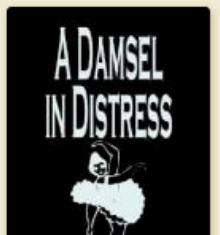
Занято



Присоединиться



Нет в библиотеке

Классические книги

OpenLibrary

Diafilmy.su

Диафильмы.SU

Поиск...

[Диафильмы \[6356\]](#) [Слайды \[787\]](#) [Диапроекторы](#) [Студии](#) [Художники](#) [Форум](#) [Регистрация](#) [Войти](#) [Добавить диафильм](#) [Контакты](#) [База диафильмов](#)

Мобильные диафильмы:

Available on the
APP STORE

Available for
SAMSUNG APPS

Android app on
GOOGLE PLAY

Download on the
MICROSOFT STORE

Новые комментарии:

Ok055, 8 сентября 2022 11:12
"Продержимся."

v-suhowey, 7 сентября 2022
19:31
"Это радует."

Baster, 7 сентября 2022 16:14
"PavelDAS, спасибо!"

Sugrob20, 7 сентября 2022
11:57
"PavelDAS, Спасибо за хорошую
новость!"

PavelDAS, 7 сентября 2022
10:49
"Sugrob20, 15 августа мне
ответил, что далеко от дома и нет
компа рядом, я ему писал, что"

Царевич и ковёр. Часть 1

Диафильм добавил: Ok055

Дата: 5.03.2022

Просмотров: 6 761

Диафильмы для самых маленьких

14

25

Алёшкино сердце

Диафильм добавил: Ok055

Дата: 10.02.2022

Просмотров: 2 243

Для тех, кто постарше

13

Царевич и ковёр. Часть 2

Диафильм добавил: Ok055

Дата: 5.03.2022

Просмотров: 2 763

Диафильмы для самых маленьких

16

Вильгельм Телль

Диафильм добавил: vlamili

Дата: 10.02.2022

Просмотров: 15 696

Для тех, кто постарше

1

51

Большой Джон

Диафильм добавил: vlamili

Дата: 5.03.2022

Просмотров: 4 205

Диафильмы для самых маленьких

21

Два знамени

Диафильм добавил: vlamili

Дата: 6.02.2022

Просмотров: 1 737

Для тех, кто постарше

20



WikiTeam

WikiTeam software is a set of tools for archiving wikis. They work on MediaWiki wikis, but we want to expand to other wiki engines. As of 2019, WikiTeam

You can check our collection at Internet Archive, the source code on GitHub and some lists of wikis by status on WikiApiary. There's also a list of

There are two completely separate projects under the umbrella of **WikiTeam**:

- The archival of the wikis in the form of XML dumps. This is what most of this page is about.
- The archival of external links found in wikis to WARCs. See the [Links warrior project](#) section.

The archival of the wikis themselves to WARCs is also desirable but has not been attempted yet.

Contents [hide]

1 Current status
2 Wikifarms
3 Wikis to archive
4 Tools and source code
4.1 Official WikiTeam tools
4.2 Other
5 Wiki dumps
5.1 Tips
5.2 BitTorrent downloads
5.3 Old mirrors
5.4 Recursive
6 Restoring wikis
7 Links warrior project
8 References
9 External links

Current status

The total number of MediaWiki wikis is unknown, but some estimates exist.

According to [WikiApiary](#), which is the most updated database, there are 21,139 independent wikis (1,718 are semantic) and 4,819 in wikifarms as of December 2018. This is the most recent estimate we have for sure.

According to Pavlo's list generated in December 2008, there are 20,000 wikis.^[2] This list was imported into WikiApiary.

According to [WikilIndex](#), there are 20,698 wikis.^[3] The URLs in this project were added to WikiApiary in the past too.

A number of [wikifarms](#) have vanished and about 180 are still online.^{[4][5][6]}

Most wikis are small, containing about 100 pages or less, but there are some very large wikis:^{[7][8]}

WikiTeam

Как и кем создаются специализированные архивы?

- **Бизнесом**

Архив телеграмма Tgstat.ru

- **Научными организациями**

Архив данных Zenodo, Software Heritage

- **Государством**

Проект OpenAIRE для хранения научных статей

- **Сообществами**

Проект Abandonia по сохранению старых игр, WikiTeam

Объективные сложности

- **Активное препятствование**

Некоторые онлайн сервисы активно препятствуют любой архивации их контента

- **Скорее архив данных чем файлов**

Требуется специальное проектирование баз данных для работы

- **Не всегда возможно проактивно**

Нет инструментов, есть препятствия со стороны источников контента

- **Иной способ подачи**

Требуются другие инструменты подачи контента, классические интерфейсы не подходят

Самые проблемные

- **Meta (Facebook, Instagram, WhatsApp и др.)**
- **Bytedance (TikTok)**
- **Pinterest**

Что такое Data takeout?

[awesome-data-takeout](#) Public

Issues Pull requests Actions Projects Wiki Security Insights Settings

master 1 branch 0 tags

 ivbeg Update README.md ...

LICENSE Initial commit

README.md Update README.md

☰ README.md

Awesome data takeout awesome

Awesome list of data export pages/tools for most common online services

Table of contents

- [Search-engines](#)
- [Social networks](#)
- [Messengers](#)
- [Email](#)
- [Business tools](#)
- [Developer tools and services](#)
- [Password managers](#)
- [Blogging](#)
- [Sport](#)

Awesome data takeout list

<https://github.com/ivbeg/awesome-data-takeout>

Список сервисов и ссылок на сервисах позволяющих забрать весь контент пользователя.

Вопросы?