



ПРАКТИКА И ОСОБЕННОСТИ ЭКСТРЕННОЙ АРХИВАЦИИ ВЕБ-РЕСУРСОВ

На примере архивных компаний Национального цифрового архива

КТО Я И ПОЧЕМУ ОБ ЭТОМ РАССКАЗЫВАЮ?



1. Много лет проектировал корпоративные и государственные data-rich проекты

2. Развиваю проект
**Национальный
цифровой архив**

3. Возглавляю АНО
Инфокультура по
открытым данным в
России и в мире

ПОЧЕМУ ЦИФРОВОЙ КОНТЕНТ ИСЧЕЗАЕТ?

- Аварии на оборудовании
- Отсутствие резервных копий
- Смерть/недееспособность владельцев
- Невозможность оплаты хостинга
- Взломы хакеров
- Ликвидация организации
- Закрытие проектов организации
- Миграция на новые программные/аппаратные решения
- Решения государственных органов

ДЛЯ ЧЕГО СОЗДАЮТ ВЕБ АРХИВЫ?

- Культурное и историческое наследие
- Сохранность особо значимых знаний
- Политическая ответственность
- Исследователи больших данных

КРУПНЕЙШИЕ ПРОЕКТЫ ПО ВЕБ-АРХИВАЦИИ



Common Crawl



Internet Archive



ArchiveTeam

А ТАКЖЕ

- Приоритет на архивацию сайтов правительств
- Более 80 национальных и академических проектов по веб-архивации в мире
- Международные организации IIPC, Digital Preservation Coalition

ЧТО ТАКОЕ BORN-DIGITAL?

Рожденный в цифре (born-digital / digital born) - термин "рожденный цифровым" (born-digital) относится к материалам, которые создаются в цифровой форме. Это отличается от процесса оцифровки, также называемого, цифровым переформатированием, посредством которого аналоговые материалы становятся цифровыми, как в случае файлов, созданных путем сканирования физических бумажных записей.

ЧТО ТАКОЕ ЦИФРОВАЯ АРХИВАЦИЯ?

Цифровая архивация (digital preservation) - это формальный подход к тому чтобы гарантировать что цифровая информация, имеющая постоянную ценность, остается доступной и пригодной для использования. Это включает планирование, распределение ресурсов и применение методов и технологий сохранения, и сочетает в себе политику, стратегии и действия для обеспечения доступа к переформатированному и "рожденному цифровым" (born-digital) контенту, независимо от проблем, связанных с неработоспособностью цифровых носителей и технологическими изменениями.

Примечание: В России цифровую архивацию также чаще называют **электронным архивированием (e-archiving)**.

ВЕБ-АРХИВАЦИЯ СЕЙЧАС

- Охватывает не все онлайн сайты из-за изменений в технологиях
Социальные сети и динамические сайты выпадают из стандартной веб-архивации
- Требует значительных технических ресурсов
Большие объёмы данных, от десятков терабайт до десятков петабайт
- Часть архивации цифровых материалов (*born digital*)
Кроме сайтов также архивируют документы, социальные сети, видео и аудио платформы
- Инициаторы - общественные организации и госархивы и библиотеки
Крупные НКО и сообщества и национальные архивы стран

СОВРЕМЕННЫЕ ПРОБЛЕМЫ ВЕБ-АРХИВАЦИИ

Ограничения социальных сетей

Большая часть социальных сетей препятствуют работе архивных роботов.

Базы данных большого объёма

Открытые данные публикуемые на многих сайтах могут достигать десятков и сотен гигабайт. Их архивация требует огромных ресурсов

Мобильные приложения

Все больше цифровых материалов распространяется только через мобильные приложения которые работают в связке приложение-сервер

Мессенджеры, каналы и чаты

Сейчас нет простых инструментов архивации общедоступных каналов и чатов, например, в Telegram, Viber и WhatsApp.

НАЦИОНАЛЬНЫЙ ЦИФРОВОЙ АРХИВ (RUARXIVE.ORG)



Национальный цифровой архив России

Russian national digital archive (ruarxive.org)

Одна из особенностей современного мира – всё большее возрастание доли материалов, создаваемых исключительно в цифровой форме. В то же время темпы долгосрочного сохранения таких материалов значительно отстают от скорости появления и уничтожения информации.

«Цифровое сохранение» – это проект по консервации и архивации ключевых цифровых ресурсов, находящихся под риском уничтожения.

Цель инициативы – поиск и сохранение веб-сайтов и иных цифровых материалов, находящихся под угрозой уничтожения.

- около 20 ТБ данных в сжатом виде
- Акцент на сфокусированной архивации
- Большая коллекция веб-архивов государственных сайтов
- Приоритет на “умирающие сайты”
- Открытый код
 - <https://github.com/infoculture>
 - <https://github.com/ruarxive>
- На основе открытых инструментов
- Не только веб-архивы, но и все остальные цифровые продукты: данные, документы и тд.

ПЛАНЫ И СТРАТЕГИЯ (ДО 2022 Г.)

- 1 Переход к непрерывной сформированной архивации Рунета. Домены: .ru, .рф, .su, .moscow
На базе Heritrix, WAIL и OpenWayback
- 2 Выделение подпроекта "Архив данных"
Запуск отдельной архивации порталов и репозиториев с открытыми данными
- 3 Выделение подпроекта "Государство"
Запуск непрерывной архивации сайтов органов власти и госучреждений.
- 4 Разработка инструментов для социальных сетей (Вконтакте, Telegram и др.)
Найм разработчиков для создания инструментов архивации данных из этих социальных сетей
- 5 Рекомендации и руководства
Перевод ключевых зарубежных руководств по веб-архивации
- 6 Просветительские курсы
Просветительские курсы для разработчиков сайтов о том как делать их пригодными для архивации.

ИЗМЕНЕНИЯ В РИСКАХ

ДО 2022 Г.

- сайты ликвидируемых органов власти
- сайты закрывающихся организаций
- закрывающиеся социальные сети/
онлайн проекты
- личные сайты с проблемами у
основателей

С 2022 Г.

- сайты СМИ признанных инагентами
- сайты самоликвидировавшихся СМИ
- контентные сайты на зарубежных хостингах
- сайты зарубежных организаций ушедших из России

ЧТО МЫ АРХИВИРОВАЛИ С 2022 ГОДА?

Сайты и телеграм каналы культурных объектов

В сотрудничестве с Музеем современного искусства Гараж и Syg.ma

Порталы открытых данных

Самостоятельная инициатива + волонтёры

Закрывающиеся медиа

Самостоятельная инициатива + волонтеры

МЕТАДАННЫЕ РЕЕСТРА ГОССАЙТОВ

- более 7700 государственных сайтов
- 31 атрибут по каждой записи
- учитывает иерархию и роль органов власти
- заполняется полуавтоматически
- не стандартизировано

A Primary	Root domain	Name	Domain type	Organization	Status
	gov.ru	Сервер органов власти РФ	Иное	ФСО России	Активно
	sudrf.ru	ГАС Правосудие	Сайт государственной власти	Судебный департамент при Правительстве РФ	Активно
	ssrf.ru	Совет судей Российской Федерации	Иное	Судебный департамент при Правительстве РФ	Активно
	vkks.ru	Высшая квалификационная комиссия судей Российской Федерации	Иное	Судебный департамент при Правительстве РФ	Активно
	government.ru	Официальный сайт Правительства Российской Федерации	Сайт органа власти	Правительство РФ	Активно
	kremlin.ru	Официальный сайт Президента Российской Федерации	Сайт органа власти	Администрация Президента Российской Федерации	Активно
	mid.ru	Официальный сайт МИД Российской Федерации	Сайт органа власти	МИД РФ	Активно
	mil.ru	Официальный сайт Министерства обороны Российской Федерации	Сайт органа власти	Минобороны РФ	Активно
	fstec.ru	Официальный сайт ФСТЭК Российской Федерации	Сайт органа власти	ФСТЭК России	Активно
minjust.gov.ru	minjust.ru	Официальный сайт Министерства юстиции Российской Федерации	Сайт органа власти	Минюст России	Переадресация
	gov.ru	Официальный сайт Министерства юстиции Российской Федерации	Сайт органа власти	Минюст России	Активно
fsin.gov.ru	fsin.su	Официальный сайт ФСИН Российской Федерации	Сайт органа власти	ФСИН России	Переадресация
	gov.ru	Официальный сайт ФСИН Российской Федерации	Сайт органа власти	ФСИН России	Активно
fssp.gov.ru	fssprus.ru	Ранее использовавшийся домен	Сайт органа власти	ФССП России	Переадресация
	gov.ru	Официальный сайт ФССП Российской Федерации	Сайт органа власти	ФССП России	Активно
roszdravnadzor.ru	roszdravnadzor.ru	Официальный сайт Росздравнадзора	Сайт органа власти	Росздравнадзор	Переадресация
	gov.ru	Официальный сайт Росздравнадзора	Сайт органа власти	Росздравнадзор	Активно

РАСШИРЕНИЕ ПЛАНОВ

1

Архив объектов цифрового культурного наследия

Что составляет культуру в сети и как это должно архивироваться?

2

Архив данных

Проект запущен и сейчас развивается

3

Архив СМИ

Архивация всех имеющихся СМИ, официальных и нет, в России, о России

4

Систематизация работы

Нужны стандарты и системная работа чтобы деятельность по архивации продолжалась непрерывно.

ПРИМЕРЫ ЭКСТРЕННОЙ АРХИВАЦИИ

ПОРТАЛ ОТКРЫТЫХ ДАННЫХ РФ (2021)

Сайт

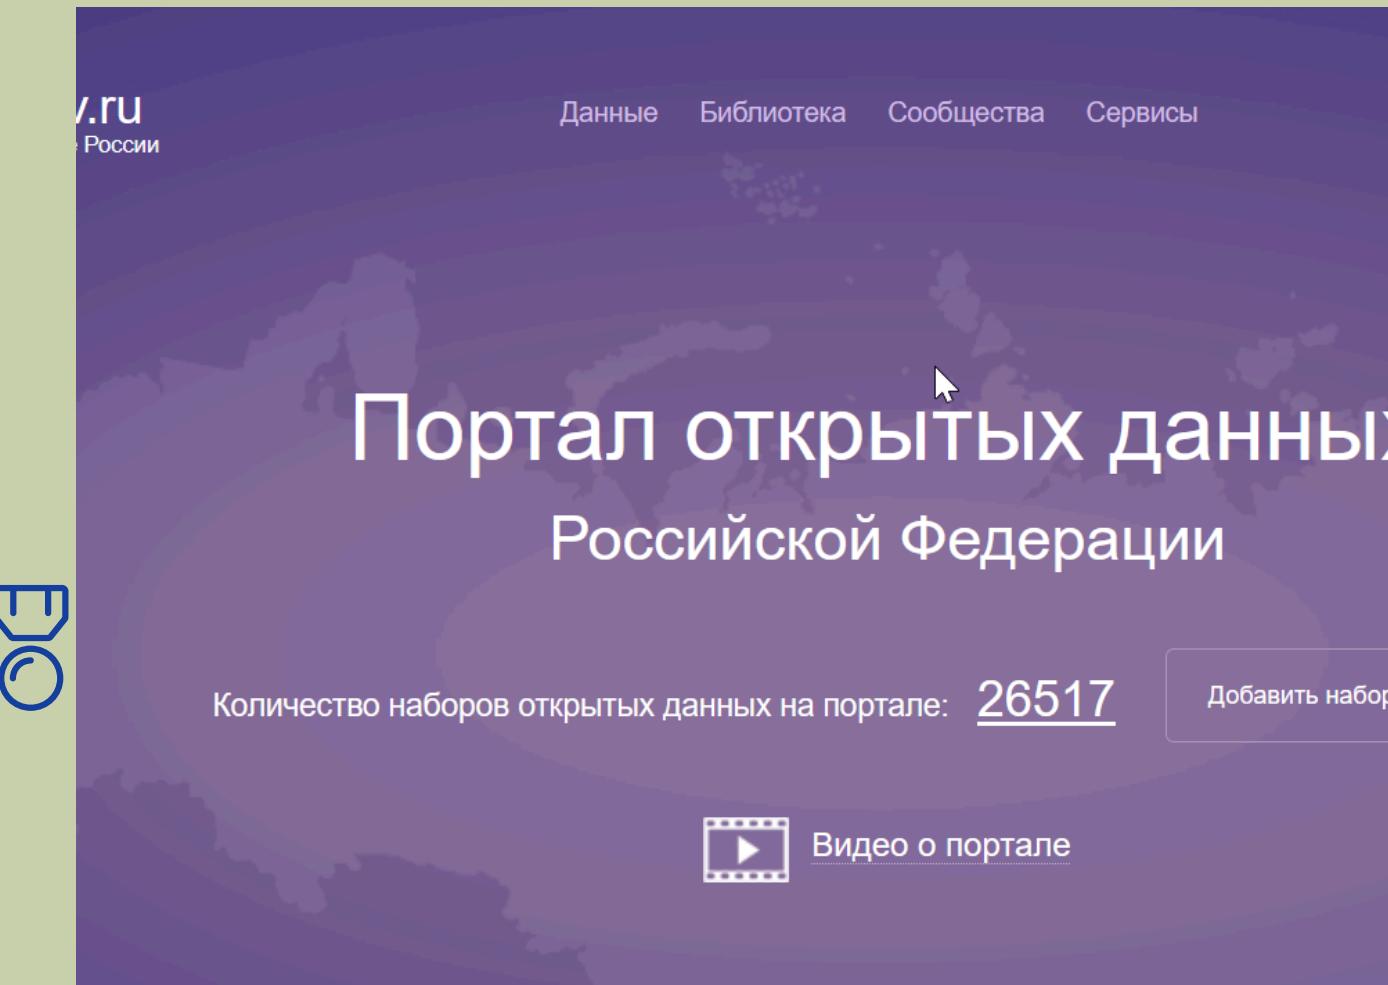
<https://data.gov.ru>

Ситуация

Нестабильно работал во время пандемии, стабильно не работал осенью 2021 г. Был отключен Минэкономразвития в начале марта 2022 г.

Результат

Была проведена полная архивация данных портала в декабре 2021 г. В конце апреля 2022 г. сотрудники Минэкономразвития РФ отписались что портал жив и продолжит работу



ЭХО МОСКВЫ (2022)

Сайт

<https://echo.msk.ru> (не работает)

Ситуация

Полная самоликвидация после решения совета директоров 3 марта 2022 г. Сайт проработал до утра 5 марта 2022 года.

Результат

Удалось сохранить значительную часть сайта, телеграм канал. Сайт сейчас находится восстанавливать по частям на основе архивов частных лиц



ZNAK.COM (2022)

Сайт

<https://znak.com> (заглушка)

Ситуация

Сайт закрыт заглушкой с 4 марта 2022 г., копий содержания нигде нет кроме онлайн краулеров Common Crawl и Archive.org

Результат

Не удалось сохранить ничего с сайта поскольку закрытие было без предупреждения



Znak.com приостанавливает работу

Мы, редакция интернет-издания Znak.com, объявляем о закрытии. Мы приостанавливаем свою работу в связи с большим количеством ограничений, которые появились в последнее время для

СОВРЕМЕННЫЕ ВЫЗОВЫ

- Как отслеживать исчезнование цифровых ресурсов?
- Как определить приоритеты архивации?
- Где найти достаточно ресурсов чтобы всё это хранить и предоставлять пользователям?
- Как обгонять Роскомнадзор с блокировками сайтов?
- Подготовка и удержание специалистов (дата инженеров со специализацией на архивации)

ОТБОР ЦИФРОВЫХ РЕСУРСОВ. ВОПРОСЫ

- Как определить значимость веб-сайта?
- Как определить глубину и частоту архивации в зависимости от значимости веб-сайта?
- Кто определяет ценность сайтов для пользователей?
- Как обеспечить сохранение исчезающего контента?

ЧТО ВАЖНО ДЛЯ ЦИФРОВОЙ АРХИВАЦИИ В РОССИИ

- 1 Институционализация цифрового сохранения
- 2 Обязательство органов власти и госструктур по обязательной передаче содержания сайтов в архив
- 3 Создание инфраструктуры добровольной передачи цифровых материалов
- 4 Организация отбора сайтов для специализированных коллекций
- 5 Перевод и принятие технических стандартов стандартов WARC, CDX, WACZ

СПАСИБО ЗА ВНИМАНИЕ!

Иван Бегтин

ibegtin@infoculture.ru