

КУРС “ЦИФРОВАЯ АРХИВАЦИЯ”

# Введение в цифровые архивы

---

# Кто я и почему об этом рассказываю?



1. Много лет проектировал корпоративные и государственные data-rich проекты

2. Развиваю проект Национальный цифровой архив

3. Возглавляю АНО Инфокультура по открытым данным в России и в мире

# Содержание курса

---

- Введение в цифровые архивы
- *Веб-архивация*
- Архивация специализированных цифровых объектов
- Инструменты цифровой архивации

# О чём мы будем говорить сегодня

---

1

**Что такое цифровая архивация и какая она бывает. Что такое digital born?**

2

**Области применения цифровых архивов: сохранение знаний, исполнение законов, цифровая forensika и др.**

3

**Ключевые задачи и этапы при цифровой архивации: планирование, сбор, сохранение, обеспечение доступа.**

4

**Виды цифровых объектов: веб-сайты, наборы данных, социальные сети и тд.**

5

**Форматы файлов, кодировки и программы. Почему важно сохранять не только контент, но и то, с помощью чего с ним работать.**

# Что такое цифровая архивация?

---

**Цифровая архивация** (*digital preservation*) - это формальный подход к тому чтобы гарантировать что цифровая информация, имеющая постоянную ценность, остается доступной и пригодной для использования. Это включает планирование, распределение ресурсов и применение методов и технологий сохранения, и сочетает в себе политику, стратегии и действия для обеспечения доступа к переформатированному и "рожденному цифровым" (*born-digital*) контенту, независимо от проблем, связанных с неработоспособностью цифровых носителей и технологическими изменениями.

**Примечание:** В России цифровую архивацию также чаще называют **электронным архивированием** (*e-archiving*).

# Что такое born-digital?

---

**Рожденный в цифре (born-digital / digital born)** - термин "рожденный цифровым" (born-digital) относится к материалам, которые создаются в цифровой форме. Это отличается от процесса оцифровки, также называемого, цифровым переформатированием, посредством которого аналоговые материалы становятся цифровыми, как в случае файлов, созданных путем сканирования физических бумажных записей.

# Примеры объектов “родденных в цифре”

Национальный исследовательский университет «Высшая школа экономики»

Декларация ценностей

Хартия (кодекс этики) работников НИУ ВШЭ

Программа развития

Цифры и факты

НИУ ВШЭ в рейтингах

История

Мы помним

## О Вышке

**Национальный исследовательский университет «Высшая школа экономики»** – это инновационный университет, осуществляющий свою миссию через научную, образовательную и социокультурную деятельность на основе международного сотрудничества, а также в качестве активной части мирового академического сообщества, осуществляющей научно-исследовательское и университетское взаимодействие ключевыми зарубежными университетами.

Веб-сайт



Фотография с соцсети (VK)

Pull requests Issues Marketplace Explore

Public

Pull requests Discussions Actions Projects 1 Wiki Security Insights

master 1 branch 3 tags Go to

ivbeg Fixed several Pylint error messages d81a8f

.idea Rewrote flatten command to support iterable data class. Ad

examples Rewrote flatten command to support iterable data class. Ad

tests Initial upload

undatum Fixed several Pylint error messages

.coveragerc Updated setup.py and requirements.txt to fix installation iss

.editorconfig Project rename to datus since name datum is used

.gitignore Fixed several Pylint error messages

AUTHORS.rst Project rename to datus since name datum is used

HISTORY.rst Added experimental query command

LICENSE Added support for CSV and BSON files for stats command

README.rst Updated documentation

flake8 Project rename to datus since name datum is used

requirements-dev.txt Added xmltodict dependency

requirements.txt Added xmltodict dependency

setup.cfg Project rename to datus since name datum is used

Код программы

**А зачем нужно  
архивировать “цифру”?**

# Цели цифровой архивации

---

- Сохранение особо ценных знаний
- Сохранение новейшей истории
- Подотчетность государства и власти
  - Любые публичные материалы органов власти
  - Цифровая форенсика (расследования)
  - Исполнение законов и регуляторных требований
- Создание общедоступных материалов для исследователей (!)

# Harvard Dataverse

dataverse.harvard.edu

Проект создан для  
сохранения научных  
данных создаваемых при  
подготовке научных работ.  
Эти знания имеют особую  
ценность

HARVARD  
Dataverse

Add Data ▾

Deposit and share your data. Get academic credit.

Harvard Dataverse is a repository for research data. Deposit data and code here.

Add a dataset +

Organize datasets and gather metrics in your own repository.

A dataverse is a container for all your datasets and metadata.

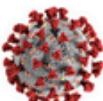
Add a dataverse +

---

Find data across research fields, preview metadata, and download files

Search over 151,300 datasets...  [VIEW ALL DATA >](#)

---

**Featured**  [COVID-19 Data Collection](#)  
A curated collection of COVID-19 data deposited in the Harvard Dataverse repository

---

Browse by subject

<a href="#">Agricultural Sciences</a> 5,051	<a href="#">Computer and Information Science</a> 2,573
<a href="#">Arts and Humanities</a> 34,612	<a href="#">Earth and Environmental Sciences</a> 8,505
<a href="#">Astronomy and Astrophysics</a> 1,161	<a href="#">Engineering</a> 1,564
<a href="#">Business and Management</a> 1,332	<a href="#">Law</a> 5,650
<a href="#">Chemistry</a> 674	<a href="#">Mathematical Sciences</a> 556

[ALL SUBJECTS >](#)

Recent datasets

# Интернет архив

archive.org

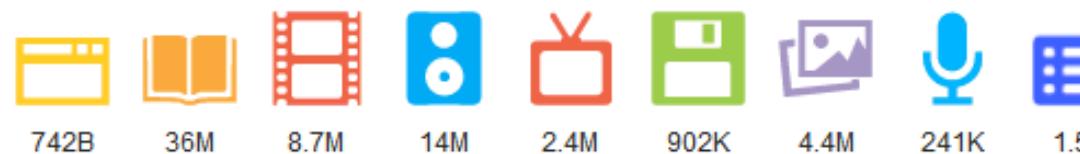
Основная цель проекта Интернет-архив в  
**сохранении современной истории в**  
максимально возможном объёме.

Search the history of over 742 billion web pages on the Internet at [archive.org](#)

WayBack Machine

enter URL or keywords

Internet Archive is a non-profit library of millions of free books, movies, software, music, websites, and more.



Search

Advanced

# UK Government Web Archive

[www.nationalarchives.gov.uk/wearchive](http://www.nationalarchives.gov.uk/wearchive)

Государственный веб архив Великобритании  
осуществляет архивацию всех  
государственных цифровых ресурсов: сайтов,  
соцсетей, видео, твитов и тд. с 1996 г. Цель  
архивации: **полная подотчетность власти**

THE NATIONAL ARCHIVES

Menu

[Home](#) > UK Government Web Archive

## UK Government Web Archive

We capture, preserve and make accessible UK central government information published on the web. The Web Archive includes videos, tweets, images and websites dating from 1996 to the present day.

### [Find archived websites](#)

Find archived websites by browsing our A-Z list or by using our full text search facility. Learn about the limitations of archived websites and see legal information about re-using web archive content.

### [Archive a website or social media channel](#)

Find out how to get a website or social media channel added to our archiving programme. Discover how to link to archived websites and see technical information about how to make your website archive compliant. Read about our take down process and learn what to do if your website is closing.

### [Find archi](#)

Find archived Twitter, pages or using our fu

### [About the](#)

Read general informa to contact us and see

# Common Crawl

[www.commoncrawl.org](http://www.commoncrawl.org)

Общедоступный открытый поисковый индекс сравнимый с поиском Google или Яндекса в виде базы данных и возможностью доступа к ретроспективным данным. Используется исследователями для обучения языковых моделей ИИ

Common Crawl

Us

We build and maintain an open repository of web crawl data that can be accessed and analyzed by anyone.

Need years of free web page data to change the world.



はい C'est vrai!  
Tak! Si.  
40+ languages  
Efectivamente. You bet.  
हाँ

\$0

1000  
HOW BIG WE'RE TALKING  
BIG  
PETABYTES

# End of term archive

eotarchive.cdlib.org

Архив всех государственных сайтов  
федеральной власти США создаваемый  
библиотекой штата Калифорния при смене  
Президента (при завершении срока  
предыдущего Президента) США. Создан для  
**обеспечения подотчетности власти**

## End of Term Web Archive US Federal Web Domain at Presidential Transitions

Home

Search Full

### [Project Background](#)

### [Project Partners](#)

### Browse by Timeframe:

[2008-2009](#)

[2012-2013](#)

[2016-2017](#)

[Browse All](#)

The End of Term Web Archive captures and saves U.S. Government websites  
EOT has thus far preserved websites from administration changes in 2008, 2012,



United States Central Command  
Sept 16, 2008



U.S. Department of State Official  
Feb 13, 2013

### Archive Scope

The End of Term Web Archive contains federal government websites (.gov, .mil) government. Websites that were at risk of changing (i.e., whitehouse.gov) or di captured. Local government websites, or any other site not part of the federal g

Масштабы.  
Другой взгляд на цели  
создания цифровых архивов.

# Цифровые архивы также могут быть...

---

- Глобальными
- Национальными
- Специализированными / тематическими
- Академическими
- Корпоративными
- Некоммерческими
- Коммерческими

# Tgstat (tgstat.ru)

Tgstat - это коммерческий проект по сбору статистики сервисов Telegram и ведению архиву и поиску по архиву всех общедоступных публикаций в Telegram

TGStat Quick search... Catalog Ratings Analytics Search by posts Telegram monitoring

Telegram channels and Russia

Promote your Telegram Channel Launch massive ad campaigns in a couple of clicks Learn more

#sponsored

Advertise on Telegram channels Launch massive ad campaigns in a couple of clicks Learn more

Verified channels

 РИА Новости 2 324 554 subscribers	 Кровавая барыня 1 360 609 subscribers
 Mash 1 664 400 subscribers	 Осторожно, новости 1 304 650 subscribers
 ЛИТВИН 1 534 338 subscribers	 Медуза — LIVE 1 256 496 subscribers

All categories

Blogs	28.1k	Marketing, PR, advertising	6.8k	Lingui
News and media	28.4k	Psychology	8.6k	Career
Humor and entertainment	19.9k	Design	2.2k	Edut
Technologies	7.7k	Politics	12.1k	Cour
Economics	8.0k	Art	3.5k	Spor
Business and startups	14.7k	Law	1.7k	Fashi
Cryptocurrencies	12.4k	Education	7.6k	Medi
Travel	7.3k	Books	5.5k	Healt

Blogs

 Кровавая барыня 1 360 609 subscribers	 Сладков + 884 579 subscribers
--	--

# Цифровые объекты

# Цифровые объекты. Тезисы

---

- **цифровые объекты (цифровые артефакты) создаются с разными целями и архивируются разными стратегиями и разными инструментами**

Например, фотография в Telegram канале сохраняется через API Telegram, а в Twitter'е через API Twitter

- **цифровые объекты отличаются по доступности.**

Например, сайты чаще доступны, а электронная почта чаще нет

- **разные цифровые объекты имеют разные форматы хранения**

Хранение изображений и документов зависит от того какими инструментами их создавали

# **Виды цифровых объектов**

---

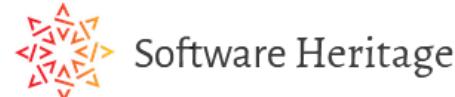
- Веб-сайты
- Цифровые тексты
- Публикации в соцсетях
- Фотографии и цифровые изображения
- Видео
- Компьютерный код
- Компьютерные программы
- Компьютерные игры
- Инженерные схемы (CAD)
- Электронная почта
- Электронные документы
- Иные двоичные файлы

# Software Heritage

[www.softwareheritage.org](http://www.softwareheritage.org)

Software Heritage это проект по архивации общедоступного открытого исходного кода.

Код собирается из таких платформ как Github, Gitlab и др.



```
4015 */
4016 static int do_sched_cfs_period_timer(struct cfs_bandwidth *cfs_b,
4017 {
4018     u64 runtime, runtime_expires;
4019     int throttled;
4020
4021     /* no need to continue the timer with no bandwidth assigned */
4022     if (cfs_b->quota == RUNTIME_INF)
4023         goto out_deactivate;
4024
4025     throttled = :list_empty(&cfs_b->throttled_sfts_q);
4026     cfs_b->nr_periods += overrun;
4027
4028     /*
4029      * idle depends on !throttled (for the case of a timer that
4030      * we're going inactive then everything will run as normal)
4031      */
4032     if (cfs_b->idle && !throttled)
4033         goto out_deactivate;
4034
4035     __refill_cfs_bandwidth_runtime(cfs_b);
4036
4037     if (!throttled) {
4038         /* mark as potentially idle for the upcoming period */
4039         cfs_b->idle = 1;
4040         return 0;
4041     }
4042
4043     /* account preceding periods in which throttling occurred */
4044     cfs_b->nr_throttled += overrun;
4045
4046     runtime_expires = cfs_b->runtime_expires;
4047
4048     /*
4049      * This check is repeated as we are holding onto the timer
4050      * we unthrottle. This can potentially race with another
4051      * trying to acquire new bandwidth from the same period.
4052  }
```

Softwa

We are building

Collect



# Форматы файлов и технологии

# Форматы файлов. Тезисы

---

- **форматы файлов могут сильно варьироваться в зависимости от вида цифрового объекта**  
Для электронных писем есть около десятка форматов их хранения, аналогично для изображений, видео и документов
- **форматы файлов неразрывно связаны с возможностью работы с ними и доступностью инструментов для такой работы**  
Например, файлы программы Lexicon из 90-х годов сейчас не открыть современными редакторами текстов
- **крупнейшие архивы создают реестры форматов файлов, рекомендации и требования к архивируемым файлам/объектам**  
Например, Национальные архивы США рекомендуют использовать открытые форматы odt вместо форматов MS Word.
- **не всегда есть возможность задать получаемые форматы файлов. При веб-архивации архивируется всё и надо уметь работать с любыми форматами**  
Например, при веб архивации собираются файлы в форматах Microsoft Visio. Автоматическая обработка этих файлов должна уметь обрабатывать такие файлы.

# Примеры форматов файлов

Это упрощённое описание, подробнее в реестрах форматов файлов

Расширение	Название	Вид объекта	Есть открытая спецификация?	Рекомендация к использованию
.PDF	Portable document format	Цифровой текст	Да	Да
.JPG	JPEG (Joint Photographic Experts Group)	Изображение	Да	Да
.DOC	MS Word Document	Цифровой текст	Частично	Да
.WARC	Web ARChive	Веб-сайт	Да	Да
.RAR	RAR Archive File	Архив	Ограниченно	Нет
.ACCDB	Microsoft Access ACCDB File	База данных	Нет	Нет

# **Реестры и руководства по архивации форматов файлов**

---

**PRONOM. The technical registry (Great Britain)**

**Digital Preservation File Format Recommendations (Canada)**

**File formats and standards (Digital Preservation Handbook)**

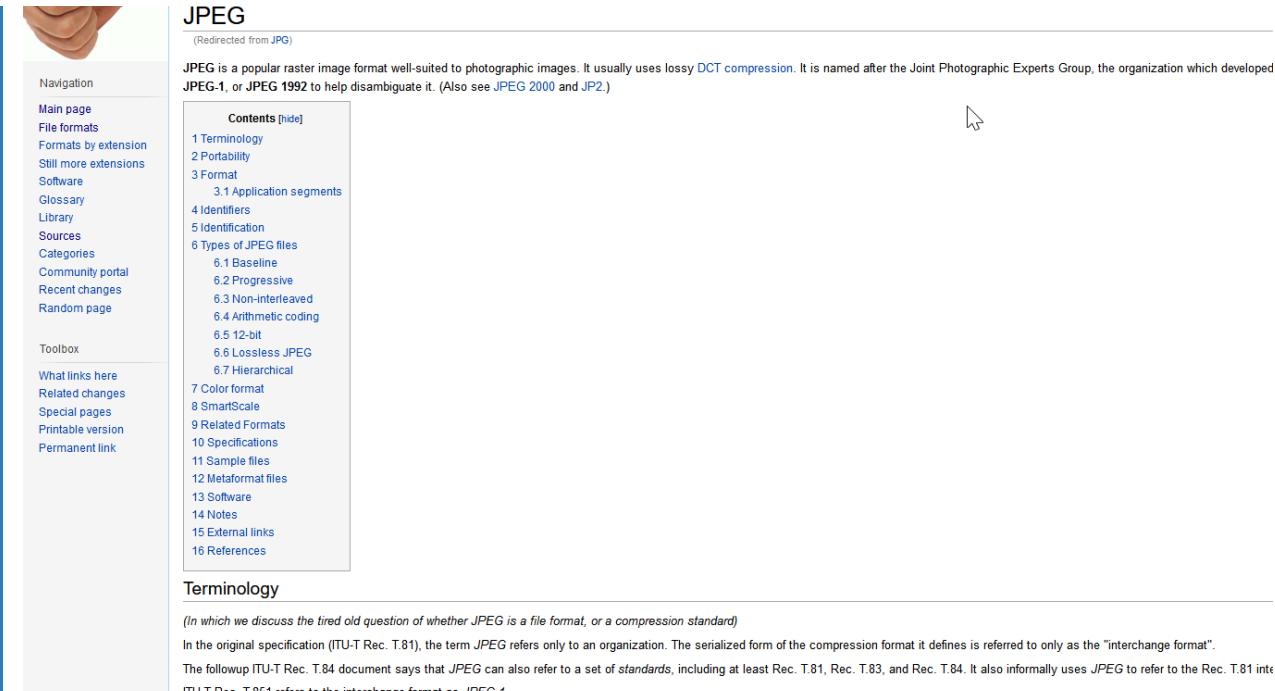
**File Formats Assessments (Great Britain)**

**File formats wiki (Archive Team community)**

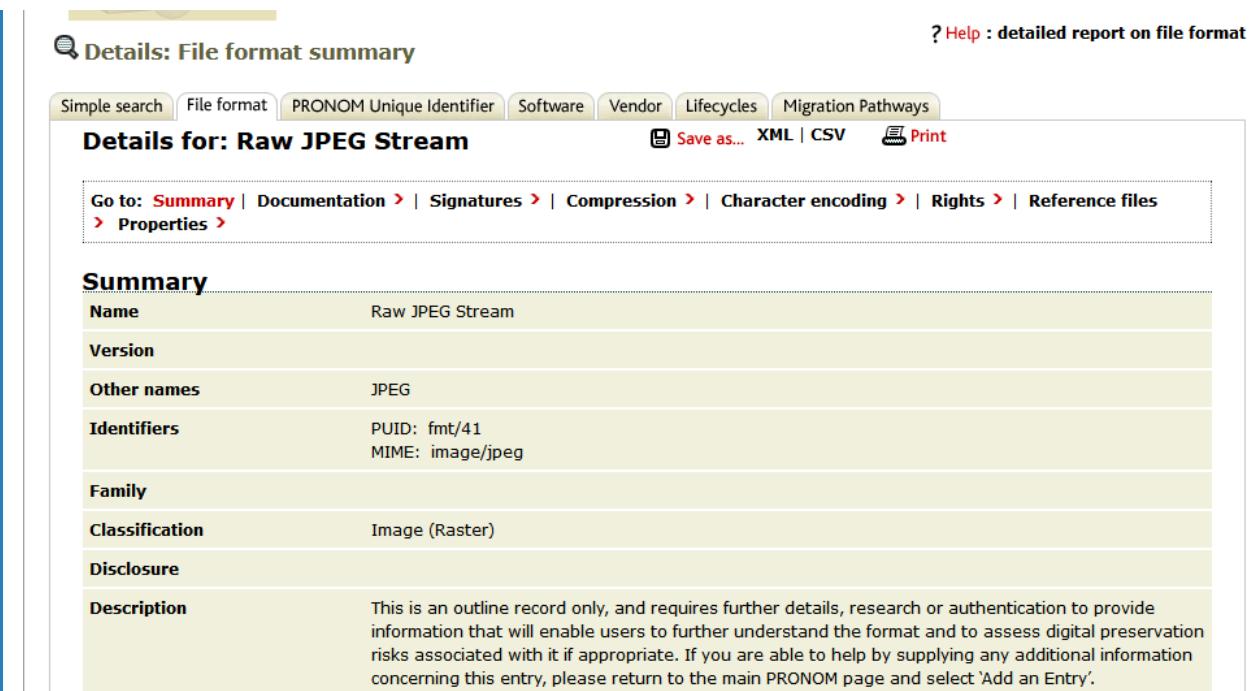
**Sustainability of Digital Formats: Planning for Library of Congress Collections (United States)**

# Формат JPEG в базе Wiki File formats от Archive Team

# Описание формата файлов JPEG в базе PRONOM



The screenshot shows the Wikipedia page for the JPEG file format. At the top right, there is a small thumbnail image of a hand holding a camera. The page has a sidebar on the left with links like 'Main page', 'File formats', 'Formats by extension', etc. The main content area starts with a brief introduction: 'JPEG is a popular raster image format well-suited to photographic images. It usually uses lossy DCT compression. It is named after the Joint Photographic Experts Group, the organization which developed JPEG-1, or JPEG 1992 to help disambiguate it. (Also see [JPEG 2000](#) and [JP2](#).)' Below this is a 'Contents' table of contents with 16 numbered sections from 'Terminology' to 'References'. A mouse cursor is visible at the top right of the page.



The screenshot shows the PRONOM details page for the 'Raw JPEG Stream' file format. At the top, there is a navigation bar with tabs: 'Simple search', 'File format', 'PRONOM Unique Identifier', 'Software', 'Vendor', 'Lifecycles', and 'Migration Pathways'. To the right of the tabs are links for 'Help', 'detailed report on file format', 'Save as...', 'XML | CSV', and 'Print'. Below the navigation bar, the title 'Details for: Raw JPEG Stream' is displayed. A breadcrumb trail shows the path: 'Go to: [Summary](#) | [Documentation](#) > | [Signatures](#) > | [Compression](#) > | [Character encoding](#) > | [Rights](#) > | [Reference files](#) > [Properties](#) >'. The page is divided into several sections: 'Summary', 'Name: Raw JPEG Stream', 'Version', 'Other names: JPEG', 'Identifiers: PUID: fmt/41, MIME: image/jpeg', 'Family', 'Classification: Image (Raster)', 'Disclosure', and 'Description: This is an outline record only, and requires further details, research or authentication to provide information that will enable users to further understand the format and to assess digital preservation risks associated with it if appropriate. If you are able to help by supplying any additional information concerning this entry, please return to the main PRONOM page and select 'Add an Entry'.'.

# Этапы и задачи

# Обобщённые ключевые этапы

---

- Планирование (planning)
- Получение/передача (transfer/acquisition)
- Загрузка контента в хранилище (ingest)
- Сохранение контента (preserve)
- Обеспечение доступа (access)

# **Планирование**

---

- определиться со стратегией архивации
- определить виды сохраняемых цифровых объектов
- выбрать инструменты архивации
- собрать ссылки, если архивация публичных ресурсов
- установить общие правила, если “регулируемых ресурсов”

# Получение

- автоматически собирать цифровые ресурсы когда это возможно
- организовать техническую инфраструктуру сбора контента
- организовать приём контента если его передают вручную

# Загрузка контента

---

- оформить контент/данные по стандартам архивации
- перенести собранный контент и данные в долгосрочное хранилище

# Сохранение контента

---

- **добавить контент в каталог**
- **извлечь метаданные из сохраненного контента**
- **обеспечить долгосрочное распределенное безопасное хранение**

# **Доступ**

---

- **создать интерфейс для доступа к контенту**
- **организовать возможность поиска по контенту**
- **создать наборы данных на основе контента**

# **Другие задачи (много задач!)**

---

**Сбор и систематизация  
ссылок на цифровые объекты  
для сохранения**

**Подготовка политик и  
требований к созданию  
контента пригодно для  
архивации**

**Каталогизация и организация  
поиска**

**Извлечение метаданных из  
собранного контента**

**Удаление чувствительной  
информации (напр.  
персональных данных)**

**Автоматизация сбора данных  
напрямую из  
первоисточников**

**Разработка требований и  
стандартизация сбора  
контента**

**Создание инструментов  
доступа и воспроизведения  
контента**

# **Модельная ситуация: цифровой архив НИУ ВШЭ**

---

## **Задачи**

- создать цифровой архив НИУ ВШЭ**
- сделать его общедоступным в сети интернет**
- на основе архива создать базы данных для курса по цифровой архивации**

# Пример списка задач по архивации. Архивация сайтов университета

## Планирование

Собрать список ссылок на сайты

Подсчитать и запросить и получить ресурсы для хранения

## Получение

Написать письма веб-мастерам

Запустить программы архивации сайтов

## Загрузка

Загрузить архивы сайтов

Чего нехватает в этом списке?

## Сохранение

Каталогизировать собранное

Извлечь метаданные из файлов

## Доступ

Организовать публичный доступ к архивам

Создать и опубликовать наборы данных для студентов

# Пример списка задач по архивации. Добавим соцсети

## Планирование

Собрать список ссылок на сайты

Подсчитать и запросить ресурсы для хранения

Собрать список ссылок на соцсети

## Получение

Написать письма веб-мастерам

Запустить программы архивации сайтов

Запустить программы архивации соцсетей

## Загрузка

Загрузить архивы сайтов

Загрузить архивы соцсетей

## Сохранение

Каталогизировать собранное

Извлечь метаданные из файлов

## Доступ

Организовать публичный доступ к архивам

Создать и опубликовать наборы данных для студентов

**Для самостоятельного изучения**

---

**Digital Preservation Handbook**

**NARA Digital Preservation Strategy 2022-2026**

**UNESCO Charter on Digital Heritage**

**UK National archives Digital preservation  
workflows**

**Вопросы?**