

КУРС “ЦИФРОВАЯ АРХИВАЦИЯ”

Веб-архивация

Веб-архивация сейчас

- **Охватывает не все онлайн сайты из-за изменений в технологиях**
Социальные сети и динамические сайты выпадают из стандартной веб-архивации
- **Требует значительных технических ресурсов**
Большие объёмы данных, от десятков терабайт до десятков петабайт
- **Часть архивации цифровых материалов (born digital)**
Кроме сайтов также архивируют документы, социальные сети, видео и аудио платформы
- **Инициаторы - общественные организации и госархивы и библиотеки**
Крупные НКО и сообщества и национальные архивы стран

Крупнейшие проекты по веб-архивации



Common Crawl

commoncrawl.org



Internet Archive

archive.org



ArchiveTeam

archiveteam.prg

Статистика архивации

1

25 петабайт: Интернет архив
Archive.org

2

5 петабайт (в сжатом виде):
Common Crawl

3

64 терабайта: Australian Web
Archive (на 2015 год) в архивах
Pandora и Trove

4

60 терабайт: Национальный
цифровой архив (ruarhive.org)

Основные потребители

- **Исследователи**

Специалисты по анализу больших данных,
разработчики алгоритмов и решений big data, отраслевые
исследовательские центры.

- **Журналисты**

Дата-журналисты и журналисты-расследователи ищащие
архивные материалы

- **Пользователи**

Ищащие потерянные документы, материалы и иные данные

Основные веб-стратегии

- **Полная индексация. Симуляция поисковой системы**
Archive.org, Common Crawl
- **Сфокусированная непрерывная индексация**
UK web archive, Australian web archive, Danish web archive
- **Выборочная управляемая регулярная архивация**
ArchiveTeam, Национальный цифровой архив, Archives Unleashed
- **Депозитарий архивов**
Архивы передаются владельцами цифрового ресурса

Классические проблемы веб архивации

Большие объёмы

Собирается очень много данных, их необходимо хранить и предоставлять пользователям.

Поисковые ловушки

Например, календарь на сайте может давать бесконечное количество ссылок, их приходится ограничивать.

Динамические сайты

Многие сайты не пригодны к архивации так как технологии на них не дают постоянных ссылок. Они используют технологии Javascript, Ajax, Flash и др.

Правообладатели

В некоторых странах архивация материалов разрешена только при условии доступа к ним через отдельные рабочие места в библиотеках

Современные проблемы веб-архивации

Ограничения социальных сетей

Большая часть социальных сетей препятствуют работе архивных роботов.

Базы данных большого объёма

Открытые данные публикуемые на многих сайтах могут достигать десятков и сотен гигабайт. Их архивация требует огромных ресурсов

Мобильные приложения

Все больше цифровых материалов распространяется только через мобильные приложения которые работают в связке приложение-сервер

Мессенджеры, каналы и чаты

Сейчас нет простых инструментов архивации общедоступных каналов и чатов, например, в Telegram, Viber и WhatsApp.

Стандарты

- **WARC - веб-архив**

Стандарт веб-архивации, цельный архив, как правило сжимаемый с помощью Gzip

- **CDX - содержание веб-архива**

Содержание веб-архива со списком всех файлов которые в него входят

- **JSON/JSONL/CSV - стандарты обмена данными**

Используется, как правило, для сохранения данных социальных сетей и данных

- **WACZ - архивированные веб-коллекции**

Расширение для формата WARC позволяющее работать с WARC файлами без полной загрузки файлов

Инструменты (открытый код)

Инструменты	Сбор (Acquisition)	Обработка и анализ (Process/Analyze)	Представление (Replay)
Веб-архивы	Heritrix, Nutch, wget, wpull, grab-site, WAIL, Brozzler	ArchiveSpark, Archives Unleashed, webarchive-discovery, warcio, warctools, metawarc	pywb, Webrecorder Player, ipwb, OpenWayback
Twitter	Social Feed Manager, Twarc, Twint, Twitter-archiver	Twitter-archiver, twitarchive, hydrator, Social Feed Manager	×
Flickr	Social Feed Manager	Social Feed Manager	×
Instagram	instaloader	×	×
Facebook	×	×	×
Вконтакте	×	×	×
Открытые данные (Open Data)	apibackuper, специальные скрипты	многочисленные инструменты и базы данных	CKAN, DKAN, DataVerse
Иные специальные ресурсы	специальные инструменты	специальные инструменты	специальные инструменты

Инструменты

технические подробности

```
DEBUG Instance <wpull.network.dns.Resolver object at 0x7f9b0c9f8710> registered event PluginFunc
inFunctions.resolve_dns
DEBUG Instance <wpull.protocol.http.client.Client object at 0x7f9b0c9f8978> registered event Cli
DEBUG Instance <wpull.protocol.ftp.client.Client object at 0x7f9b0c9f8a58> registered event Client
DEBUG Instance <wpull.processor.rule.FetchRule object at 0x7f9b0c9f8fd0> registered event PluginF
inFunctions.fetch
DEBUG Instance <wpull.processor.rule.FetchRule object at 0x7f9b0c9f8fd0> registered hook PluginF
inFunctions.fetch
DEBUG Instance <wpull.processor.rule.ResultRule object at 0x7f9b0c9b80b8> registered event Plugi
nFunctions.result
DEBUG Instance <wpull.processor.rule.ResultRule object at 0x7f9b0c9b80b8> registered event Plugi
nFunctions.result
DEBUG Instance <wpull.processor.rule.ResultRule object at 0x7f9b0c9b80b8> registered event Plugi
nFunctions.result
DEBUG Instance <wpull.processor.rule.ResultRule object at 0x7f9b0c9b80b8> registered event Plugi
nFunctions.result
DEBUG Instance <wpull.processor.rule.ResultRule object at 0x7f9b0c9b80b8> registered event Plugi
nFunctions.result
DEBUG Instance <wpull.processor.rule.ResultRule object at 0x7f9b0c9b80b8> registered event Plugi
nFunctions.result
DEBUG Instance <wpull.processor.rule.ResultRule object at 0x7f9b0c9b80b8> registered hook PluginF
inFunctions.result
DEBUG Instance <wpull.processor.rule.ResultRule object at 0x7f9b0c9b80b8> registered hook PluginF
inFunctions.result
DEBUG Instance <wpull.processor.rule.ProcessingRule object at 0x7f9b0c9b8160> registered event P
rocessing
DEBUG Instance <wpull.application.tasks.stats.StatsStopTask object at 0x7f9b0d0f8a20> registered
DEBUG Instance <wpull.application.tasks.shutdown.AppStopTask object at 0x7f9b0d0f8f98> registered
DEBUG Instance <wpull.application.tasks.shutdown.AppStopTask object at 0x7f9b0d0f8f98> registered
DEBUG Found plugin download_progress_plugin_py from /usr/local/lib/python3.6/dist-packages/wpull-
DEBUG Found plugin debug_console_plugin_py from /usr/local/lib/python3.6/dist-packages/wpull-2.0-
DEBUG Found plugin arg_warning_plugin_py from /usr/local/lib/python3.6/dist-packages/wpull-2.0.3-
DEBUG Found plugin server_response_plugin_py from /usr/local/lib/python3.6/dist-packages/wpull-2-
DEBUG Parsing URL http://hse.ru
DEBUG Parsed URL <URLInfo at 0x7f9b0c7194e0 url=http://hse.ru/ raw=http://hse.ru>
DEBUG Rewritten URL <URLInfo at 0x7f9b0c719630 url=http://hse.ru/ raw=http://hse.ru/?#>
DEBUG Wrote file /tmp/wpull-20220111-10144-16160-10144.warc
```

Команда

```
wpull http://hse.ru --strip-session-id --no-check-certificate --
no-robots --page-requisites --no-parent --sitemaps --inet4-
only --timeout 20 --tries 3 --waitretry 5 --recursive --level inf -
--span-hosts --retry-connrefused --retry-dns-error --delete-
after --warc-append --warc-cdx -U "Mozilla/5.0 (Windows NT
10.0; Win64; x64; rv:91.0) Gecko/20100101 Firefox/91.0" -d -a
hse.ru/hse.ru.log --database hse.ru/hse.ru.db --warc-file
"hse.ru/hse.ru" --warc-header "operator: Ivan Begtin" --warc-
header "downloaded-by: Ruarhive.org" --domains hse.ru --
concurrent 4
```

Wpull

<https://github.com/ArchiveTeam/wpull>

- архивирует сайты в формат WARC
- сохраняет в базу данных sqlite все собранные ссылки
- только командная строка
- работает под Linux Ubuntu 18.04
- ! не обновлялся 6 лет

≡ ← → ⌂ ⌂ https://ncmu.ru/docs/

Новости События Вопрос-ответ Вакансии Контакты



НАУЧНЫЕ ЦЕНТРЫ
МИРОВОГО УРОВНЯ

Центры

Официальные документы

НЦМУ — Документы

Документы

Протоколы конкурсной комиссии по экспертизе документов

Protokol_dopuska_2-A_1.06.PDF
от 01 июня 2020 | 450.54 КБ

Protokol_dopuska_2-B.PDF
от 01 июня 2020 | 238.7 КБ

Protokol_dopuska_2-D.PDF
от 01 июня 2020 | 419.04 КБ

Protokol_dopuska_2-E.PDF
от 01 июня 2020 | 246.04 КБ

Протокол вскрытия конвертов с документами для участ

Protokol_vskrytiya_konvertov_s_zayavkami.pdf
№ 1 | от 13 мая 2020 | 457.93 КБ

ArchiveWeb.page

<https://github.com/webrecorder/archiveweb.page>

- позволяет просматривать веб-архивы на настольном компьютере
- поддерживает форматы WARC и WACZ
- только GUI
- Windows, Linux, Mac
- в онлайне есть как <https://replayweb.page>

The screenshot shows a Jupyter Notebook interface with the following details:

- Title:** parquet_text_analysis.ipynb
- File Menu:** File, Edit, View, Insert, Runtime, Tools, Help
- Toolbar:** Back, Forward, Refresh, URL bar (https://colab.research.google.com/github/archivesunleashed/no), Stop, Run, Cell, Help, Copy to Drive, Connect.
- Section:** Word Cloud
- Description:** Word clouds are always fun, right?! They're an interesting way to visualize word frequency, as the more times that a word occurs, the larger it will appear in the word cloud.
- Note:** Let's setup some dependencies here. We will install the `wordcloud` library, and setup some stop words via `nltk`.
- Code Cells:**
 - [1]:

```
#capture  
!pip install wordcloud  
from wordcloud import WordCloud, STOPWORDS, ImageColorGenerator
```
 - [2]:

```
french_wordcloud = WordCloud(width=2000, height=1500, scale=10, max_font_size=250, max_words=100, background_color="white")  
plt.figure(figsize=[35,10])  
plt.imshow(french_wordcloud, interpolation="bilinear")  
plt.axis("off")  
plt.show()
```
 - [3]:

Archives Unleashed

<https://archivesunleashed.org>

- **работа с архивами сайтов как с большими данными**
- **интегрируется в Jupyter Notebook**
- **удобно для исследовательской работы**

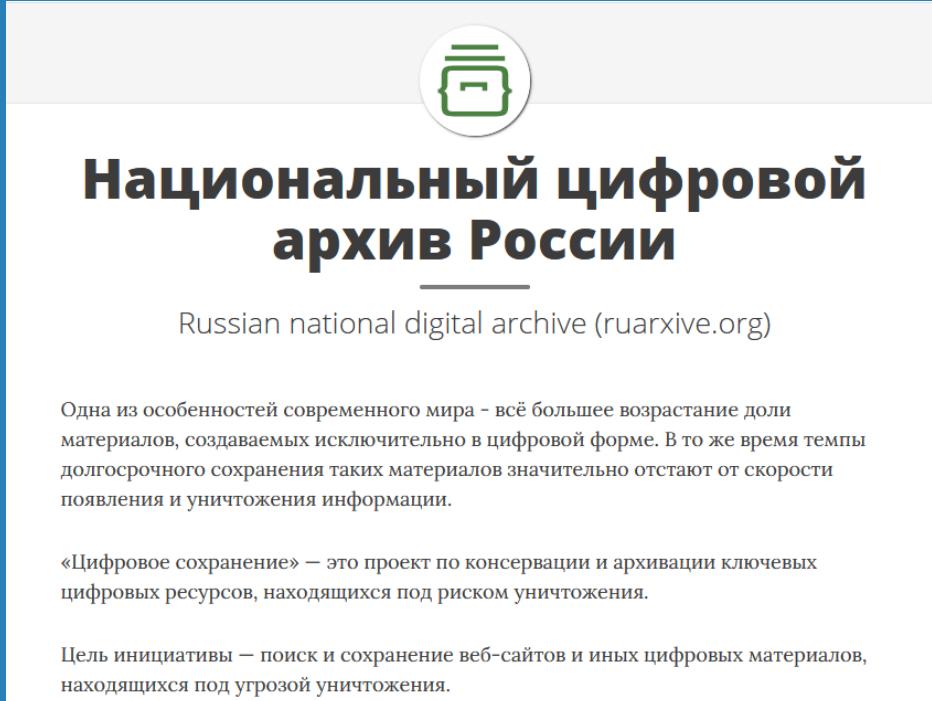
Metawarc

<https://github.com/datacoon/metawarc/>

- анализ WARC файлов
- работает с командной строки
- умеет подсчитывать объёмы файлов по типам и извлекать метаданные

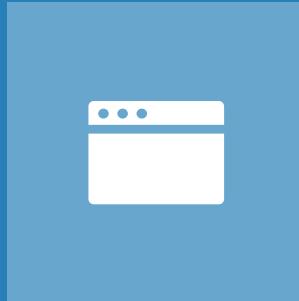
mimes	files	size	share
application/javascript	10	8900825	46.0255
image/svg+xml	390	2690464	13.9122
text/html	1098	1932935	9.99507
application/x-font-ttf	8	1362448	7.04512
text/css	5	1199959	6.2049
image/jpeg	5	1052523	5.44252
application/font-woff	8	633736	3.277
application/vnd.ms-fontobject	8	550736	2.84782
application/pdf	3	510379	2.63913
font/woff2	8	418344	2.16323
application/vnd.openxmlformats-officedocument.spreadsheetml.sheet	1	37274	0.192741
image/png	9	34851	0.180212
	33	7317	0.0378357
image/x-icon	2	2790	0.0144269
image/gif	2	2200	0.011376
application/json	1	2110	0.0109107
#total	1591	19338891	100

Национальный цифровой архив (ruarhive.org)



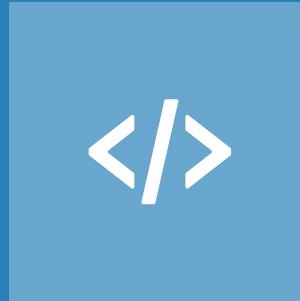
- **около 20 ТБ
данных в сжатом
виде**
- **Акцент на
сфокусированной
архивации**
- **Большая
коллекция веб-
архивов
государственных
сайтов**
- **Приоритет на
“умирающие
сайты”**
- **Открытый код**
 - <https://github.com/infoculture>
 - <https://github.com/ruarhive>
- **На основе
открытых
инструментов**
- **Не только веб-
архивы, но и все
остальные
цифровые
продукты: данные,
документы и тд.**

Инструменты НЦА



Используем

- **wpull, wget, grab-site** - сбор веб-архивов
- **twarc** - сбор твитов
- **pywb** - представление веб-архивов
- **СКАН** - каталогизация архивных коллекций
- **aut** - анализ веб-архивов



Создаём

- **apiarchiver** - архивация открытых данных публикуемых как API
- **metawarc** - извлечение метаданных из архивных документов
- **undatum** - обработка данных
- **govdomains** - реестр всех доменов госорганов и госучреждений
- **wparc** - утилита архивации сайтов на Wordpress



Russian national digital archive

Проект по цифровому сохранению знаний связанных с материалами на русском языке

3 followers Moscow <https://ruarxive.org> infoculture@infoculture.ru

Overview

Repositories 19

Projects 1

Packages

Teams 1

...

Pinned

[apibackuper](#) Public

Python library and cmd tool to backup API calls

● Python ⭐ 10 🏷 2

[ruarxive-research](#) Public

Материалы исследований, зафиксированные в цифровом архиву

⭐ 3

[awesome-digital-preservation](#) Public

Awesome list dedicated to digital and data preservation tools, sources, services and so on.

⭐ 4 🏷 2

[wparc](#) Public

Wordpress API data and files

● Python ⭐ 5 🏷 1

[Repositories](#)

Find a repository...

Type ▾

...

[apibackuper](#) Public

Python library and cmd tool to backup API calls

Открытый код на Github

github.com/ruarxive

Что важно для цифровой архивации в России (то чего нет)?

- 1 Отбор иных цифровых ресурсов для создания
“Архива данных”
- 2 Определение структуры метаданных для веб-архива
- 3 Создание инфраструктуры добровольной передачи цифровых материалов
- 4 Перевод и принятие стандартов WARC, CDX, WACZ
- 5 Организация отбора сайтов для специализированных коллекций
- 6 Институционализация цифрового сохранения

Отбор цифровых ресурсов. Вопросы

- Как определить значимость веб-сайта?
- Как определить глубину и частоту архивации в зависимости от значимости веб-сайта?
- Кто определяет ценность сайтов для пользователей?
- Как обеспечить сохранение исчезающего контента?

Каталоги и метаданные

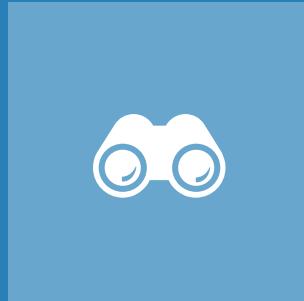
- Используются сейчас: Dublin Core, OAI-РНМ, WARC, CDX
- Нет универсального стандарта метаданных для веб-сайтов
Но есть рекомендации OCLC
<https://archive.org/services/docs/api/metadata-schema/index.html> и
схема метаданных Интернет-архива
- Можно ли сделать универсальный стандарт или использовать расширения для специализированных архивов?

Метаданные реестра госсайтов

- более 7700 государственных сайтов
- 31 атрибут по каждой записи
- учитывает иерархию и роль органов власти
- заполняется полуавтоматически
- не стандартизировано

A Primary...	Root domain	A Name	Domain type	Organization	Sta...
	gov.ru	Сервер органов власти РФ	Иное	ФСО России	Актив...
	sudrf.ru	ГАС Правосудие	Сайт государственной...	Судебный департамент при	Актив...
	ssrf.ru	Совет судей Российской ...	Иное	Судебный департамент при	Актив...
	vkks.ru	Высшая квалификационн...	Иное	Судебный департамент при	Актив...
	government.ru	Официальный сайт Прави...	Сайт органа власти	Правительство РФ	Актив...
	kremlin.ru	Официальный сайт Прези...	Сайт органа власти	Администрация Президента	Актив...
	mid.ru	Официальный сайт МИД ...	Сайт органа власти	МИД РФ	Актив...
	mil.ru	Официальный сайт Минобо...	Сайт органа власти	Минобороны РФ	Актив...
	fstec.ru	Официальный сайт ФСТЭ...	Сайт органа власти	ФСТЭК России	Актив...
minjust.gov.ru	minjust.ru	Официальный сайт Миню...	Сайт органа власти	Минюст России	Пере...
	gov.ru	Официальный сайт Миню...	Сайт органа власти	Минюст России	Актив...
fsin.gov.ru	fsin.su	Официальный сайт ФСИН...	Сайт органа власти	ФСИН России	Пере...
	gov.ru	Официальный сайт ФСИН...	Сайт органа власти	ФСИН России	Актив...
fssp.gov.ru	fssprus.ru	Ранее использовавшийся ...	Сайт органа власти	ФССП России	Пере...
	gov.ru	Официальный сайт ФССП ...	Сайт органа власти	ФССП России	Актив...
roszdravnadz...	roszdravnadzor.ru	Официальный сайт Росзд...	Сайт органа власти	Росздравнадзор	Пере...
	gov.ru	Официальный сайт Росзд...	Сайт органа власти	Росздравнадзор	Актив...

Роль архивистов и библиотекарей



Отбор веб-сайтов для архивации

- Определение конкретных сайтов или типов/групп сайтов подлежащих автоматической архивации.
- Формирование списков специальных коллекций



Ведение каталогов и заполнение метаданных

- Заполнение метаданных в каталогах по каждому цифровому объекту хранения
- Актуализация метаданных при необходимости



Взаимодействие с сообществом

- Принятие цифровых материалов на хранение от гражданских архивистов
- Поощрение участия гражданских архивистов в архивных проектах

Материалы для самостоятельного изучения

- **Где взять архивы сайтов и данных?**
<https://cdn.ruarxive.org/public/>
- **Где найти инструменты цифровой архивации?**
<https://github.com/ruarxive/awesome-digital-preservation>
- **Где прочитать про то как пользоваться инструментами?**
 1. <https://ruarxive.org/kb/intro>
 2. <https://wiki.archiveteam.org/index.php/Software>
 3. https://wiki.archiveteam.org/index.php/The_WARC_Ecosystem
- **Где узнать какие есть инициативы по сохранению веб-сайтов?**
https://en.wikipedia.org/wiki/List_of_Web_archiving_initiatives

Вопросы?